ПРОГРАММА ПРОФЕССИОНАЛЬНОЙ ПЕРЕПОДГОТОВКИ

"Аналитик данных: с нуля до разработки прикладных решений для бизнеса"

ИТОГОВЫЙ ПРОЕКТ

Сегментация клиентской базы телекоммуникационной компании

Выполнил: Панькина Александра Ивановна

Номер группы: ДА-801

Год защиты: 2023

АНАЛИТИЧЕСКАЯ ЗАДАЧА

> Провести комплексный анализ данных с целью выделения наиболее типичных групп клиентов и разработки персонализированных предложений для каждого сегмента

01
Первичная обработка данных
Подготовка датасета: очистка, стандартизация форматов, обработка пропусков

02
Добавление новых переменных
Создание производных метрик для углубленного анализа поведения клиентов

03
Исследовательский анализ данных
Выявление паттернов, трендов и взаимосвязей в клиентской базе

04
Выводы и рекомендации
Формулировка бизнес-инсайтов на основе результатов анализа

ИСХОДНЫЕ ДАННЫЕ

Основой исследования стал документ Excel, содержащий детальные данные о клиентах телекоммуникационной компании с многомерными характеристиками их поведения и предпочтений.

РЕЗУЛЬТАТ ПЕРВИЧНОГО АНАЛИЗА:

- Данные загружены корректно и готовы к обработке
- Выявлена необходимость коррекции типов данных: даты подключения (object → datetime64), звонки ночью (object → float64)
- Обнаружены пропущенные значения, требующие обработки

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4492 entries, 0 to 4491
Data columns (total 11 columns):
 #   Column                                 Non-Null Count  Dtype
---  ------                                 --------------  -----
 0   Возраст                                4492 non-null   int64
 1   Среднемесячный расход                  4468 non-null   float64
 2   Средняя продолжительность разговоров   4475 non-null   float64
 3   Звонков днем за месяц                  4472 non-null   float64
 4   Звонков вечером за месяц               4489 non-null   float64
 5   Звонков ночью за месяц                 4492 non-null   object
 6   Звонки в другие города                 4492 non-null   object
 7   Звонки в другие страны                 4492 non-null   int64
 8   Доля звонков на стационарные телефоны  4492 non-null   object
 9   Количество SMS за месяц                4492 non-null   object
 10  Дата подключения тарифа                4492 non-null   object
dtypes: float64(4), int64(2), object(5)
memory usage: 386.2+ KB
```

```
df = pd.read_csv('/content/dataset_telecom.csv') # загружаем ДФ
df
```

	Возраст	Среднемесячный расход	Средняя продолжительность разговоров	Звонков днем за месяц	Звонков вечером за месяц	Звонков ночью за месяц	Звонки в другие города	Звонки в другие страны	Доля звонков на стационарные телефоны	Количество SMS за месяц	Дата подключения тарифа
0	24	NaN	2.4	12.0	65.0	5	0	0	5	56	2018-06-17 12:14:35
1	51	287.51	1.7	111.0	109.0	1	44	0	6	1	2021-10-21 15:39:54

ПЕРВИЧНАЯ ОБРАБОТКА ДАННЫХ

1 **Коррекция заголовков столбцов**

Стандартизация наименований для корректной обработки данных

2 **Приведение типов данных**

Конвертация форматов для обеспечения точности вычислений

3 **Проверка дублирующихся записей**

Выявление и устранение потенциальных дубликатов в датасете

До коррекции:

```
# корректируем заголовки
df.rename(columns = {'среднемесячный расход' : 'среднемесячный_расход',
                     'средняя продолжительность разговоров' : 'средняя_продолжительность_разговоров',
                     'звонков днем за месяц' : 'звонков_днем_за_месяц',
                     'звонков вечером за месяц' : 'звонков_вечером_за_месяц',
                     'звонков ночью за месяц' : 'звонков_ночью_за_месяц',
                     'звонки в другие города' : 'звонки_в_другие_города',
                     'звонки в другие страны' : 'звонки_в_другие_страны',
                     'доля звонков на стационарные телефоны' : 'звонки_стационарные_телефоны',
                     'количество sms за месяц' : 'sms_за_месяц',
                     'дата подключения тарифа' : 'дата_подключения_тарифа'
                     },
          inplace=True)
df.columns
```

После коррекции:

```
df = df.astype({'дата_подключения_тарифа' :
```

```
'datetime64'})#преобразование строкового признака в дату
```

```
[17] df.duplicated().sum()
```

```
0
```

ВЫВОД: дублирующихся записей не обнаружено.

ОБНАРУЖЕНИЕ И ОБРАБОТКА АНОМАЛИЙ

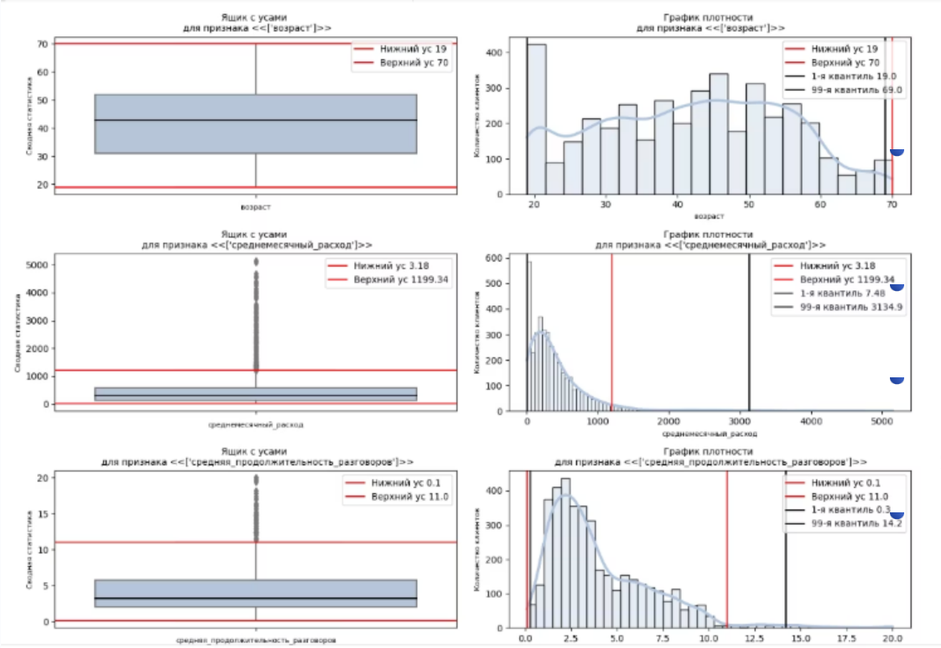

Возраст: аномалий не выявлено, пик 19-20 лет

Расходы: аномалии от 1199.34 руб.

Продолжительность: выбросы от 11 минут

SMS: аномальные значения от 75 сообщений

СТРАТЕГИЯ ОБРАБОТКИ: Сохранение данных по 99-му квантилю. При удалении по верхним усам остается только 71% записей, что критично снижает репрезентативность выборки.

Детальный анализ показал наличие естественных выбросов, характерных для телекоммуникационной отрасли: VIP-клиенты с высокими расходами и активные пользователи с интенсивным трафиком.

СОЗДАНИЕ НОВЫХ ПЕРЕМЕННЫХ

Для углубленного анализа клиентского поведения были созданы дополнительные аналитические переменные, обогащающие исходный датасет.

Возрастные категории

Сегментация клиентов по жизненным этапам для таргетированного маркетинга

```
new_df[["возраст", 'возрастная_категория']].head(10)
```

	возраст	возрастная_категория
1	51	бизнесмен
2	41	бизнесмен
3	35	бизнесмен

Временные паттерны

Анализ динамики подключений и активности пользователей

$$\text{Возрастная категория} = \begin{cases} \text{студент}, & \text{если Возраст} \in [19, 24]; \\ \text{аспирант}, & \text{если Возраст} \in [25, 33]; \\ \text{бизнесмен}, & \text{если Возраст} \in [34, 56]; \\ \text{знаток}, & \text{если Возраст} \in [57, 70]. \end{cases}$$

Поведенческие метрики

Комплексные показатели использования услуг связи

```
#генерирование новых признаков
new_df['год_подключения'] = new_df['дата_подключения_тарифа'].dt.year
new_df['месяц_подключения'] = new_df['дата_подключения_тарифа'].dt.strftime('%Y-%m')
new_df['месяц'] = pd.to_datetime(new_df['дата_подключения_тарифа']).dt.strftime('%B')
new_df['дата_подключения'] = new_df['дата_подключения_тарифа'].dt.date
```

год_подключения	месяц_подключения	месяц	дата_подключения
2021	2021-10	October	2021-10-21
2015	2015-03	March	2015-03-26

ДИНАМИКА ПОДКЛЮЧЕНИЙ К ТАРИФАМ

Анализ временных паттернов подключения клиентов к тарифным планам показывает стабильную динамику роста клиентской базы.

По годам

Устойчивый рост подключений с небольшими сезонными колебаниями

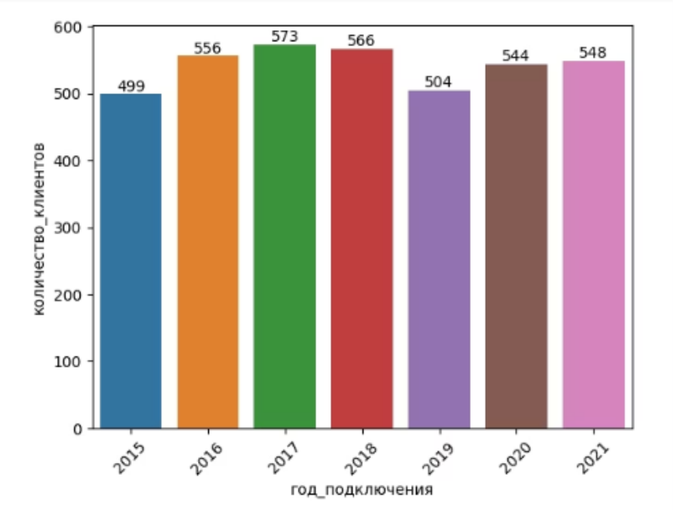

По месяцам

Выраженная сезонность с пиками в определенные периоды года

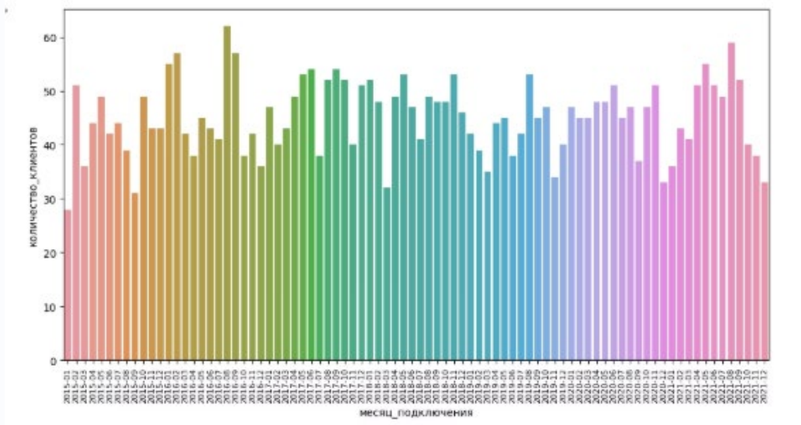

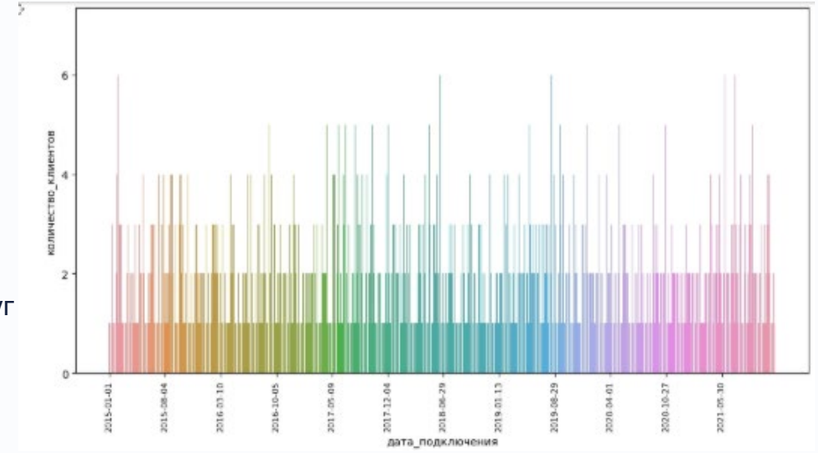

По дням недели

Предпочтения клиентов к определенным дням для оформления услуг

КЛЮЧЕВОЙ ВЫВОД: Консистентность временных паттернов подключения по всем временным интервалам подтверждает стабильность бизнес-модели и предсказуемость клиентского поведения.

ПОВЕДЕНЧЕСКИЕ ХАРАКТЕРИСТИКИ ПО ВОЗРАСТАМ

Исследование распределения ключевых метрик в разрезе возрастных категорий

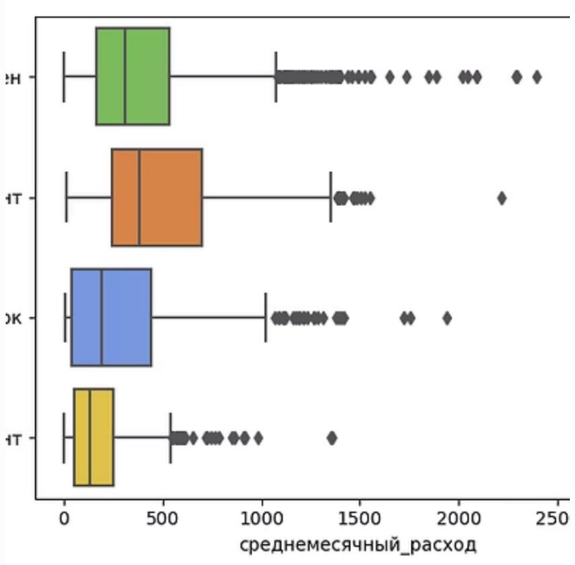

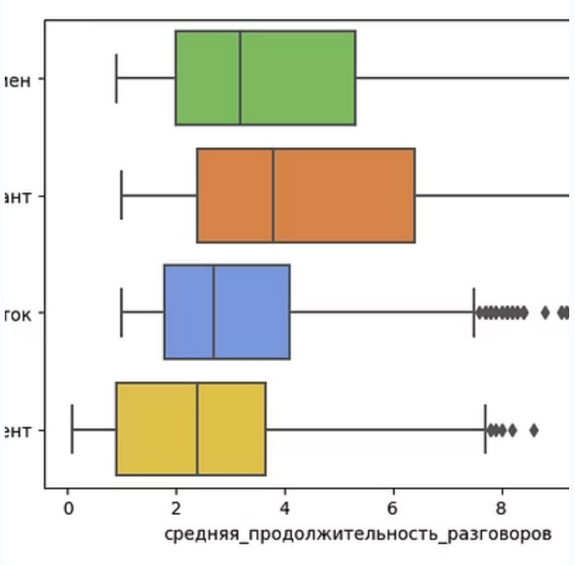

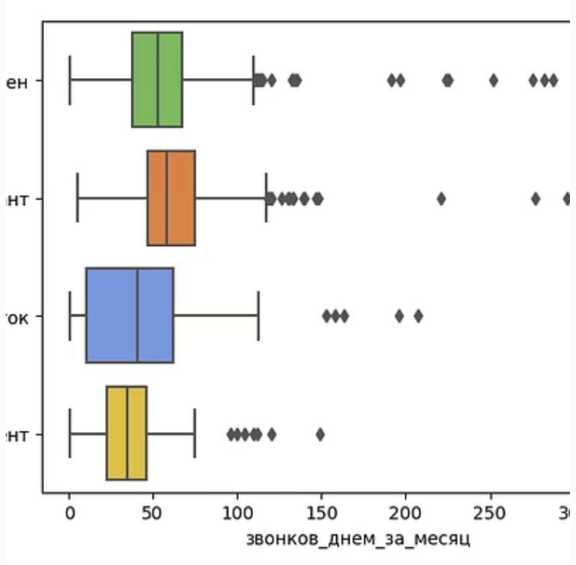

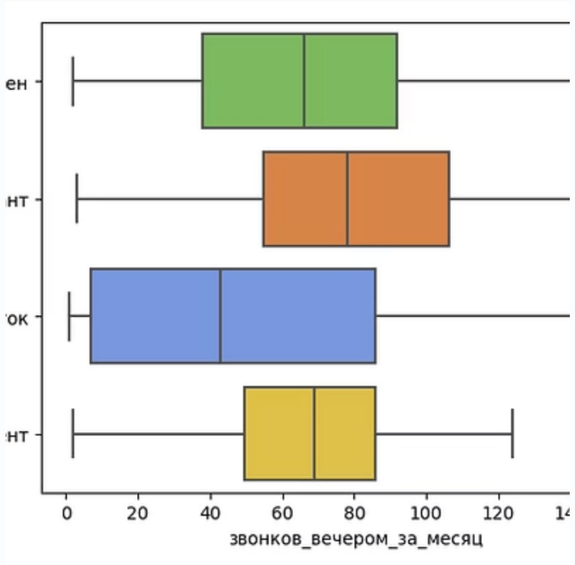

Расходы

Максимальные у бизнесменов и аспирантов

Длительность

Более продолжительные разговоры у старших групп

Дневные звонки

Студенты звонят днем реже остальных

Вечерние звонки

Аспиранты лидируют по активности

ДОПОЛНИТЕЛЬНЫЕ ПОВЕДЕНЧЕСКИЕ ИНСАЙТЫ

Углубленный анализ специфических паттернов использования услуг связи различными возрастными сегментами.

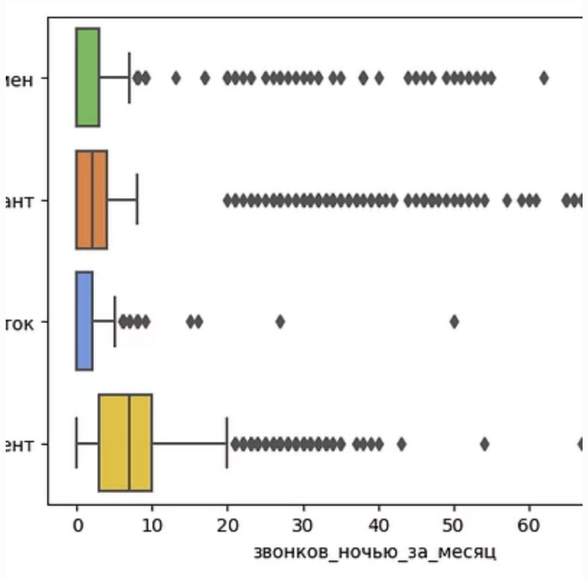

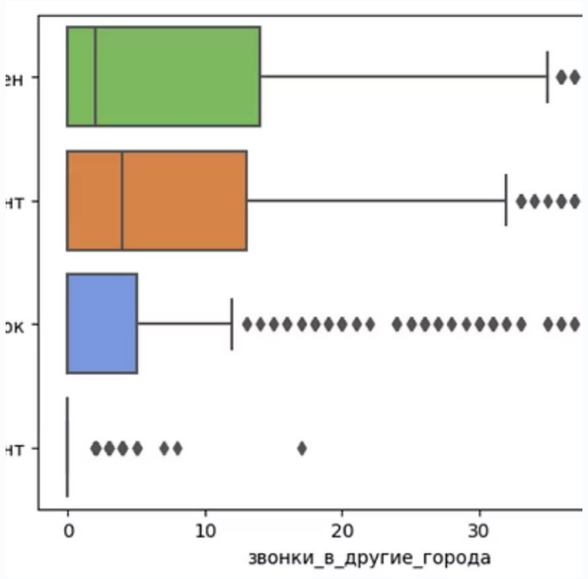

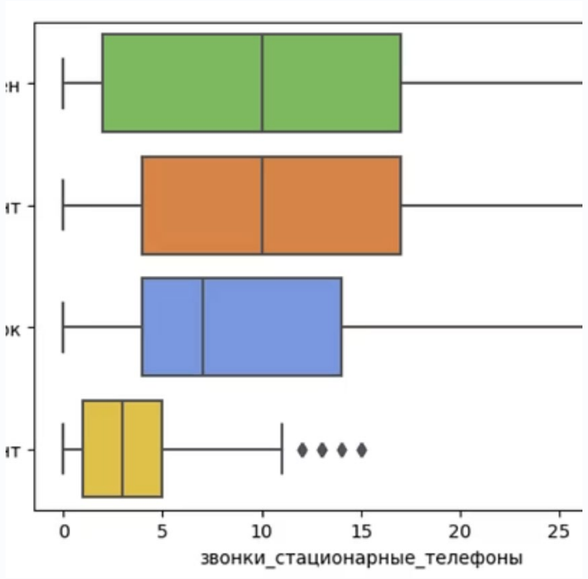

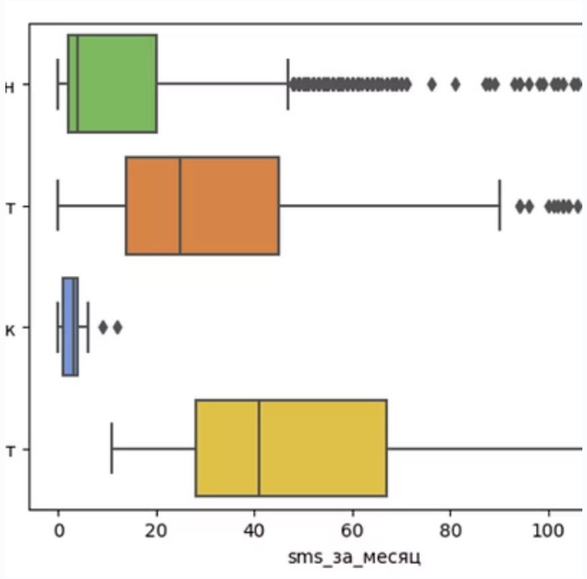

Ночная активность

Студенты — основные пользователи ночных звонков

Междугородние звонки

Бизнесмены и аспиранты активнее используют связь с другими городами

Стационарная связь

Аспиранты и бизнесмены чаще звонят на стационарные номера

SMS-сообщения

Студенты лидируют по количеству отправляемых сообщений

Проведенный анализ выявил четкую дифференциацию поведенческих паттернов между возрастными группами, что создает основу для разработки целевых продуктовых предложений и маркетинговых кампаний